



UNIVERSITÉ DE FIANARANTSOA
ÉCOLE DE MANAGEMENT ET D'INNOVATION
TECHNOLOGIQUE

MENTION : Informatique
PARCOURS : Science de Données et Intelligence Artificielle

MÉMOIRE DE FIN D'ANNÉE
Pour le passage en deuxième année de Master

CONCEPTION ET RÉALISATION D'UN MODÈLE DE
DEEP LEARNING POUR LA RESTAURATION ET
RECONSTRUCTION D'IMAGES

Présenté par : NOMENJANAHARY Pierre Andrianajoro

Matricule: 4637

Année Universitaire : 2023-2024

INTRODUCTION

La restauration d'images est un domaine clé dans le traitement d'images, avec des applications variées allant de la préservation d'archives historiques à l'amélioration de la qualité des photos personnelles. Avec l'augmentation des besoins en restauration rapide et précise d'images fortement dégradées, la recherche dans ce domaine s'est considérablement intensifiée.

Cependant, malgré les progrès des méthodes traditionnelles et des approches récentes basées sur l'intelligence artificielle, plusieurs défis demeurent. En particulier, la restauration d'images comportant des dégradations complexes telles que les brûlures, les déchirures, ou la perte de parties significatives reste un problème difficile à résoudre. De plus, les approches existantes nécessitent souvent des ressources computationnelles importantes ou des quantités massives de données d'entraînement, ce qui limite leur application à grande échelle.

Face à ces défis, ce projet vise à développer une application de restauration d'images basée sur des techniques de Deep Learning, en exploitant la puissance des autoencodeurs convolutifs. Le modèle proposé est conçu pour gérer divers types de dégradations et produire des images restaurées de haute qualité.

Ce mini-mémoire est structuré comme suit :

- la première partie présente l'état de l'art en matière de restauration d'images, en détaillant les approches existantes et leurs limites.
- la deuxième partie décrit la méthodologie utilisée, comprenant la préparation des données, la conception du modèle, et les stratégies d'entraînement.
- Enfin, les résultats obtenus sont discutés avant de conclure sur les contributions de ce projet et les perspectives pour des travaux futurs.

Chapitre 1. ÉTAT DE L'ART

1.1 Introduction à la Restauration d'Images

La restauration d'images est une discipline du traitement d'images visant à améliorer la qualité d'images dégradées en reconstruisant les informations perdues. Elle trouve des applications variées, notamment dans la préservation d'archives historiques, la médecine, les médias, et la photographie. L'objectif est de transformer une image dégradée pour qu'elle soit visuellement acceptable ou exploitable pour des traitements ultérieurs.

1.2 Méthodes existantes

1.2.1 Méthodes traditionnelles

Les premières approches pour la restauration d'images ont principalement reposé sur des techniques traditionnelles issues du traitement d'images numériques. Ces méthodes, bien que simples à mettre en œuvre, présentent des limites significatives lorsqu'il s'agit de traiter des dégradations complexes ou multiples.

1.2.1.1 Filtrage spatial et Fréquentiel

Le filtrage spatial est une méthode classique qui consiste à appliquer un noyau de convolution sur une image pour réduire le bruit ou améliorer ses détails. Par exemple, les filtres gaussiens ou médian appliquent un lissage pour réduire le bruit aléatoire. En parallèle, les techniques de filtrage fréquentiel, telles que la transformée de Fourier, permettent d'isoler et de traiter les fréquences responsables des dégradations.

Cependant, ces approches souffrent de limitations majeures. Le filtrage spatial tend à flouter les contours, entraînant une perte de détails. De même, le filtrage fréquentiel, bien que puissant, exige une expertise significative pour sélectionner les fréquences à traiter, rendant son application limitée en pratique. [1]

1.2.1.2 Techniques d'Interpolation

Les techniques d'interpolation, telles que l'interpolation bilinéaire ou bicubique, sont utilisées pour combler des parties manquantes dans une image ou augmenter sa résolution. Elles reposent sur des hypothèses mathématiques simples pour estimer les valeurs des pixels manquants. Bien qu'efficaces pour des dégradations légères ou des zones petites, ces méthodes échouent lorsque les parties manquantes représentent une proportion significative de l'image ou comportent des textures complexes.

Une étude récente menée par Zhang et al. (2020) a démontré que l'interpolation bilinéaire produit des résultats peu convaincants pour des images présentant des dégradations irrégulières, notamment en cas de déchirures ou de brûlures. Les auteurs concluent que ces techniques sont mal adaptées aux applications nécessitant une reconstruction précise des détails visuels. [2]

1.2.1.3 Les modèles statistiques.

Les modèles statistiques, tels que les méthodes basées sur la minimisation de l'énergie, se sont avérés utiles pour la restauration d'images, notamment en remplissant des zones manquantes ou en réduisant le bruit. Ces méthodes exploitent des hypothèses sur les distributions des pixels pour reconstruire les régions dégradées de manière cohérente avec les parties intactes de l'image.

Par exemple, la méthode de restauration bayésienne repose sur la probabilité a posteriori des pixels à reconstruire, en utilisant des distributions statistiques adaptées aux caractéristiques de l'image. Chan et Shen (2005) ont proposé un modèle basé sur des équations aux dérivées partielles pour l'inpainting local non texturé, qui minimise une énergie fonctionnelle afin de combler les lacunes dans l'image. Cette approche produit des résultats visuellement acceptables pour des dégradations simples, mais sa généralisation est limitée face à des dégradations multiples ou complexes. [3]

De même, Criminisi et al. (2004) ont introduit une méthode d'inpainting basée sur l'analyse statistique des textures environnantes. Bien que cette méthode soit efficace pour des images comportant des motifs répétitifs, elle échoue souvent à reconstruire des détails fins ou des textures non homogènes. [4]

Les approches probabilistes globales, telles que celles proposées par Levin et al. (2011), ont également exploré la régularisation spatiale pour traiter les dégradations diffuses. Cependant, ces modèles sont computationnellement coûteux, ce qui les rend moins pratiques pour des applications à grande échelle. [5]

Malgré leurs promesses, ces approches dépendent fortement des hypothèses sur la distribution des pixels et de la structure de l'image. En présence de dégradations sévères ou de zones manquantes importantes, elles produisent souvent des reconstructions irréalistes, ce qui limite leur adoption dans des scénarios pratiques. [1]

1.3 Méthodes Modernes Basées sur le Deep Learning

L'émergence de l'apprentissage profond a révolutionné le domaine de la restauration d'images en permettant une reconstruction plus précise et visuellement convaincante des images dégradées. Ces méthodes exploitent des architectures avancées, telles que les réseaux neuronaux convolutifs (CNN), les autoencodeurs, les réseaux antagonistes génératifs (GAN), et les autoencodeurs variationnels (VAE), pour surmonter les limites des approches traditionnelles.

1.3.1 Les réseaux neuronaux convolutifs (CNNs)

Les réseaux neuronaux convolutifs (CNNs) sont devenus un standard pour la restauration d'images grâce à leur capacité à apprendre des représentations complexes directement à partir des données. En utilisant des convolutions successives, les CNNs peuvent extraire des caractéristiques hiérarchiques, allant des détails locaux aux structures globales.

Zhang et al. (2017) ont proposé une méthode appelée DnCNN (Denoising Convolutional Neural Network), qui utilise un CNN profond pour éliminer le bruit dans les images. Ce modèle a montré une robustesse accrue par rapport aux méthodes traditionnelles, en s'adaptant à divers types de bruit. Cependant, les CNNs classiques ont parfois du mal à gérer les pertes importantes de données ou les dégradations sévères. [6]

1.3.2 Autoencodeurs

Les autoencodeurs sont particulièrement adaptés à la restauration d'images. Composés d'un encodeur et d'un décodeur, ils apprennent à compresser une image dans un espace latent (représentation réduite) puis à la reconstruire. Cela permet de corriger les erreurs ou de combler les parties manquantes.

Un exemple marquant est l'étude de Pathak et al. (2016), qui ont utilisé un autoencodeur convolutif pour l'inpainting d'images. Leur modèle, basé sur une fonction de perte contextualisée, a montré des résultats convaincants pour combler les zones manquantes tout en préservant les textures environnantes. Cependant, les autoencodeurs souffrent parfois de reconstructions trop lisses, manquant de détails réalistes. [7]

1.3.3 Les réseaux antagonistes génératifs (GANs)

Les réseaux antagonistes génératifs (GANs) ont apporté une avancée majeure dans la restauration d'images, en générant des détails réalistes grâce à une compétition entre un générateur et un discriminateur. Isola et al. (2017) ont introduit Pix2Pix, un modèle GAN conditionnel capable de traduire des images de basse qualité en versions améliorées. [8]

De même, Ledig et al. (2017) ont développé SRGAN (Super-Resolution GAN), qui améliore la résolution des images avec des résultats saisissants. [9]

Cependant, les GANs sont notoirement difficiles à entraîner, nécessitant des ajustements précis pour éviter des problèmes tels que le mode collapse (où le modèle génère des images similaires sans diversité).

1.3.4 Autoencodeurs Variationnels (VAE)

Les VAE étendent les autoencodeurs classiques en intégrant une composante probabiliste dans la reconstruction des images. Ils sont particulièrement utiles pour générer des échantillons plausibles dans des zones fortement dégradées. Kingma et Welling (2014) ont proposé une architecture VAE qui a été adaptée pour des tâches de restauration complexes. Bien que puissants, les VAE produisent souvent des images légèrement floues, car leur fonction de perte favorise des reconstructions globalement cohérentes plutôt que des détails fins. [10]

Après tous, les méthodes basées sur le Deep Learning présentent des avantages significatifs par rapport aux approches traditionnelles. Elles peuvent gérer des dégradations complexes, apprendre des caractéristiques directement à partir des données, et produire des reconstructions réalistes. En revanche, elles nécessitent des ensembles de données massifs pour un entraînement efficace et des ressources matérielles importantes, ce qui peut limiter leur accessibilité.

1.4 Tableau Comparatif des Méthodes

Méthode	Avantages	Inconvénients
Filtrage Spatial/Frequentiel	Simple à implémenter, rapide à exécuter.	Inefficace pour des dégradations complexes ou multiples.
Techniques d'Interpolation	Utile pour des zones manquantes petites ou régulières.	Résultats peu réalistes pour des textures complexes ou des pertes importantes.
Modèles Statistiques	Exploitent des informations globales et locales pour une cohérence spatiale.	Computationnellement coûteux, fortement dépendants des hypothèses sur les données.
CNNs	Apprennent des caractéristiques complexes à partir des données, robustes aux variations.	Moins adaptés aux grandes pertes de données, nécessitent beaucoup de données.
Autoencodeurs	Reconstruisent efficacement les images dégradées, architecture simple et modulaire.	Résultats parfois lisses, manquant de détails.
GANs	Produisent des images très réalistes, apprennent des détails fins.	Difficiles à entraîner, problèmes de stabilité (mode collapse).
VAE	Intègrent une approche probabiliste pour combler les zones manquantes.	Génèrent souvent des images légèrement floues.

1.5 Synthèse

Les méthodes traditionnelles, bien qu'historiquement importantes dans le domaine de la restauration d'images, montrent des limites significatives lorsqu'il s'agit de traiter des dégradations complexes ou multiples. Des techniques comme le filtrage ou l'interpolation, tout en étant simples et rapides, produisent souvent des résultats insuffisants, notamment pour les pertes d'informations importantes ou les textures non homogènes. De même, les modèles statistiques, bien qu'ils offrent une approche plus cohérente sur le plan spatial, souffrent de leur coût computationnel élevé et de leur dépendance à des hypothèses parfois irréalistes.

En revanche, les méthodes modernes basées sur l'apprentissage profond ont révolutionné le domaine grâce à leur capacité à apprendre des représentations riches et complexes directement à partir des données. Les CNNs, par exemple, se distinguent par leur robustesse et leur capacité à généraliser sur des ensembles de données variés. Les GANs, quant à eux, produisent des résultats visuellement saisissants en intégrant des détails réalistes dans les zones fortement dégradées. Cependant, ces modèles présentent également des défis, notamment une complexité accrue et des exigences importantes en termes de données et de puissance de calcul.

Face à ces constats, le choix d'un autoencodeur convolutif apparaît comme la solution la plus appropriée pour ce projet. Cette approche combine simplicité, efficacité, et robustesse. Les autoencodeurs permettent de capturer et de reconstruire des informations essentielles, même en présence de dégradations multiples, tout en étant plus simples à entraîner que les GANs et plus adaptés aux scénarios nécessitant une reconstruction structurée. En utilisant un modèle d'autoencodeur conçu pour gérer différentes dégradations (flou, bruit, masquage, vieillissement, etc.), ce projet vise à offrir une solution équilibrée entre performances et accessibilité.

En conclusion, l'adoption d'un autoencodeur convolutif garantit une restauration d'images efficace tout en optimisant les ressources nécessaires à son déploiement. Ce choix s'impose donc comme la solution la plus pertinente pour répondre aux défis identifiés dans ce projet.

Chapitre 2. MÉTHOLOGIE

2.1 Introduction

La méthodologie adoptée dans ce projet repose sur une approche structurée et rigoureuse visant à résoudre le problème de restauration d'images dégradées à l'aide d'un modèle d'apprentissage profond. Pour atteindre cet objectif, plusieurs étapes clés ont été suivies, allant de la préparation des données à la conception, l'entraînement et l'évaluation du modèle. Chaque étape a été soigneusement planifiée afin d'assurer une cohérence entre les données utilisées, l'architecture du modèle et les métriques d'évaluation choisies.

La stratégie méthodologique repose sur l'utilisation d'un autoencodeur convolutif, un modèle reconnu pour son efficacité dans les tâches de reconstruction d'images. Ce modèle a été entraîné sur un ensemble de données riche et diversifié, comprenant des images originales et leurs versions dégradées générées artificiellement. Une attention particulière a été portée à la préparation des données, à l'ajustement des paramètres du modèle et à l'évaluation de ses performances afin de garantir des résultats fiables et robustes.

Cette section présente en détail les données utilisées, l'architecture du modèle, les choix techniques et les outils employés, ainsi que la stratégie adoptée pour l'entraînement et la validation du modèle.

2.2 Description des Données

Les données utilisées dans ce projet jouent un rôle essentiel dans l'entraînement et l'évaluation du modèle de restauration d'images. L'ensemble de données de base a été constitué à partir de la célèbre base DIV2K (Diverse 2K Resolution Dataset), largement utilisée dans le domaine du traitement d'images. Cette base contient des images haute définition qui servent de référence pour de nombreuses tâches liées à l'amélioration et à la reconstruction d'images. Le choix de cette base s'explique par sa diversité et sa qualité, offrant des exemples variés en termes de scènes, de textures et de détails.

Pour simuler les images dégradées nécessaires à l'entraînement, plusieurs types de transformations artificielles ont été appliqués aux images originales. Ces transformations incluent l'ajout de bruit gaussien, le floutage, le masquage partiel, la décoloration et l'introduction de dommages simulant des brûlures ou des déchirures. Chaque image originale a été associée à plusieurs versions dégradées, générées de manière aléatoire pour refléter une large gamme de scénarios de dégradations réelles. Au total, 15 000 images dégradées ont été produites à partir des images de la base DIV2K.

L'ensemble de données final a été divisé en deux sous-ensembles distincts. Le premier, représentant 80 % des données, a été réservé à l'entraînement du modèle. Le second, correspondant à 20 % des données, a été utilisé pour la validation afin d'évaluer les performances du modèle sur des données non vues pendant l'entraînement. Chaque sous-ensemble a été soigneusement équilibré pour inclure une variété d'images et de dégradations.

Les images utilisées dans ce projet ont toutes été redimensionnées à une résolution uniforme de 128x128 pixels afin de garantir une cohérence dans les données d'entrée du modèle. Avant leur utilisation, les valeurs des pixels ont été normalisées entre 0 et 1 pour améliorer la stabilité et l'efficacité de l'entraînement.

Cette description des données met en évidence l'importance d'une préparation rigoureuse et d'une diversification des scénarios de dégradations pour entraîner un modèle robuste et performant.

2.3 Architecture du modèle

Le modèle utilisé dans ce projet est un autoencodeur convolutif, une architecture spécialement conçue pour les tâches de reconstruction d'images. L'autoencodeur se compose de deux parties principales : l'encodeur et le décodeur.

L'encodeur est responsable de réduire progressivement la dimensionnalité de l'image d'entrée tout en préservant ses caractéristiques essentielles. Cela est accompli à l'aide de couches de convolution suivies de couches de sous-échantillonnage (max-pooling). Ces transformations permettent au modèle de capturer les structures globales de l'image tout en éliminant les détails superflus.

Le décodeur, quant à lui, reconstruit l'image à partir des représentations compactes produites par l'encodeur. Il utilise des couches de convolution et de suréchantillonnage (upsampling) pour générer une image de sortie ayant la même dimension que l'image originale. La dernière couche du modèle applique une activation sigmoïde pour normaliser les valeurs des pixels entre 0 et 1.

Pour ce projet, l'architecture exacte du modèle a été définie comme suit :

❖ Entrée :

Une image dégradée de dimensions 128x128x3.

❖ Encodeur :

- Une couche de convolution (64 filtres, taille 3x3, activation ReLU, padding "same"), suivie d'une couche de max-pooling (2x2).

- Une deuxième couche de convolution (32 filtres, taille 3x3, activation ReLU, padding "same"), suivie d'une autre couche de max-pooling (2x2).

❖ Décodeur :

- Une couche de convolution (32 filtres, taille 3x3, activation ReLU, padding "same"), suivie d'une couche de suréchantillonnage (2x2).

- Une deuxième couche de convolution (64 filtres, taille 3x3, activation ReLU, padding "same"), suivie d'une autre couche de suréchantillonnage (2x2).

- Une dernière couche de convolution (3 filtres, taille 3x3, activation sigmoïde, padding "same") pour produire l'image restaurée.

Cette architecture a été choisie pour sa simplicité et son efficacité dans les tâches de reconstruction. Elle est capable de capturer les relations complexes entre les pixels tout en restant facile à entraîner.

Enfin, une fonction de perte basée sur l'erreur quadratique moyenne (Mean Squared Error, MSE) a été utilisée pour mesurer la différence entre l'image restaurée et l'image originale. Ce choix garantit que le modèle apprend à minimiser les écarts entre ces deux images de manière progressive et stable.

2.4 Stratégie d'entraînement

L'entraînement du modèle repose sur une stratégie méthodique visant à optimiser la qualité des images restaurées tout en assurant une convergence stable et rapide. Cette stratégie comprend plusieurs étapes clés, depuis la préparation des données jusqu'au suivi des performances.

Avant l'entraînement, les images dégradées (ensemble d'entrée) et les images originales correspondantes (ensemble cible) ont été normalisées pour que leurs valeurs de pixels soient comprises entre 0 et 1. Cette normalisation est essentielle pour stabiliser les gradients et accélérer la convergence du modèle.

Le modèle a été entraîné à minimiser une fonction de perte basée sur l'erreur quadratique moyenne. Pour optimiser cette fonction, l'algorithme Adam a été utilisé comme optimiseur, avec un taux d'apprentissage initial fixé à 0,001. Adam est reconnu pour sa capacité à ajuster dynamiquement les taux d'apprentissage pour chaque paramètre du modèle, ce qui améliore la convergence, même dans des architectures complexes comme les autoencodeurs.

L'entraînement a été réalisé sur 50 époques avec un batch size de 32. Ces paramètres ont été choisis pour assurer un équilibre entre la vitesse d'entraînement et la stabilité des gradients. À chaque époque, les performances du modèle ont été évaluées sur un ensemble de validation, permettant de surveiller sa capacité à généraliser sur des données non vues.

Deux métriques supplémentaires ont été utilisées pour évaluer la qualité des images restaurées :

- ❖ PSNR (Peak Signal-to-Noise Ratio) : Mesure la qualité globale de l'image restaurée, exprimée en décibels. Une valeur élevée indique une meilleure qualité.
- ❖ SSIM (Structural Similarity Index) : Évalue la similitude structurelle entre l'image originale et l'image restaurée, en tenant compte des contrastes et textures locaux.

Enfin, pour éviter tout surapprentissage, une stratégie d'arrêt anticipé (early stopping) a été mise en place, surveillant les performances sur l'ensemble de validation. Si aucune amélioration significative n'était observée pendant plusieurs époques consécutives, l'entraînement était interrompu afin de préserver un modèle optimal.

Cette stratégie d'entraînement assure que le modèle est non seulement performant sur les données d'entraînement, mais également capable de généraliser efficacement à des scénarios de dégradations variés.

2.5 Outils et environnement technique

Le développement et l'entraînement du modèle de restauration d'images ont nécessité l'utilisation d'outils logiciels et matériels adaptés aux exigences du projet.

Sur le plan logiciel, le langage Python a été choisi pour sa flexibilité et ses nombreuses bibliothèques dédiées au traitement d'images et à l'apprentissage profond. Les principales bibliothèques utilisées incluent :

- ❖ TensorFlow/Keras : Framework principal pour concevoir, entraîner et évaluer le modèle d'apprentissage profond.
- ❖ OpenCV : Utilisé pour la manipulation et la transformation des images, notamment pour la génération des dégradations artificielles.
- ❖ NumPy : Fournissant un support efficace pour la manipulation des matrices et des tableaux multidimensionnels.
- ❖ Matplotlib : Utilisé pour visualiser les résultats intermédiaires, tels que les comparaisons entre les images restaurées et originales.

Enfin, pour assurer la reproductibilité et l'organisation du projet, un environnement virtuel Python a été utilisé afin d'isoler les dépendances nécessaires. Cet environnement a été configuré avec toutes les bibliothèques requises, assurant une compatibilité totale avec le code source.

Cet ensemble d'outils et de ressources a permis de répondre aux exigences techniques du projet tout en garantissant une exécution fluide et efficace des différentes étapes, de la préparation des données à l'entraînement du modèle.

2.6 Outils et environnement technique

Le processus méthodologique suivi dans ce projet peut être résumé en un ensemble d'étapes structurées et interconnectées. Tout d'abord, les images originales ont été collectées à partir de la base de données DIV2K, puis des versions dégradées ont été générées à l'aide de transformations artificielles variées. Ces données ont ensuite été organisées en ensembles d'entraînement et de validation, permettant d'assurer une évaluation rigoureuse des performances du modèle.

L'autoencodeur convolutif, conçu pour reconstruire les images originales à partir de leurs versions dégradées, a été entraîné en minimisant l'erreur quadratique moyenne. Le modèle a été évalué à l'aide de métriques standard, notamment le PSNR et le SSIM, garantissant une restauration de qualité.

Chapitre 3. RÉSULTATS ET DISCUSSION

3.1 Présentation des résultats

Les résultats obtenus dans ce projet montrent la capacité du modèle d'autoencodeur convolutif à restaurer des images présentant divers types de dégradations. Après entraînement, le modèle a été évalué qualitativement en comparant les images restaurées avec leurs versions originales et dégradées.

L'objectif principal était de tester la capacité du modèle à reconstruire des images proches des originales, même en présence de dégradations complexes comme les brûlures, les déchirures ou les flous importants. Les résultats visuels révèlent une amélioration significative de la qualité des images restaurées, avec une restitution cohérente des textures et des détails.

Cette section présente les observations qualitatives clés à travers des exemples illustratifs, tout en analysant les forces et les limites du modèle dans différents scénarios de dégradations.

3.2 Analyse Qualitative

Pour évaluer qualitativement les performances du modèle, des exemples représentatifs ont été sélectionnés parmi l'ensemble de validation. Chaque exemple compare trois versions de l'image : la version dégradée, la version restaurée par le modèle, et l'image originale.

Les observations montrent que le modèle est capable de gérer efficacement plusieurs types de dégradations :

- ❖ Flou et bruit : Les images restaurées montrent une réduction significative du flou et une suppression du bruit, tout en conservant les détails structurels. Les contours et les textures apparaissent plus nets, proches des originaux.
- ❖ Vieillesse et décoloration : Le modèle restaure avec succès les couleurs originales, éliminant les effets de décoloration et préservant les contrastes.

- ❖ Dommages physiques (brûlures et déchirures) : Bien que la reconstruction des zones brûlées ou déchirées soit imparfaite dans certains cas, le modèle parvient généralement à produire des résultats visuellement acceptables, en comblant les parties manquantes de manière cohérente avec le contexte.
- ❖ Masquage des parties manquantes : Le modèle reconstruit les zones masquées de manière fluide, même si des pertes de détails peuvent être observées dans les textures complexes.

Les exemples visuels révèlent que les résultats sont globalement satisfaisants pour des dégradations modérées à sévères. Cependant, certains cas montrent des limites, notamment dans la gestion des textures très détaillées ou des zones entièrement perdues.

3.3 Discussion

Les résultats obtenus mettent en évidence plusieurs forces du modèle utilisé dans ce projet. Tout d'abord, l'autoencodeur convolutif a démontré une capacité remarquable à gérer une large gamme de dégradations, allant du flou et du bruit au vieillissement et aux dommages physiques. La qualité des reconstructions produites est globalement satisfaisante, avec des images restaurées qui sont visuellement proches des originales.

L'une des principales forces du modèle est sa capacité à restaurer des zones manquantes ou fortement dégradées de manière contextuelle, en s'appuyant sur les informations des régions environnantes. Cette caractéristique est particulièrement utile dans des scénarios de masquage ou de dommages physiques, où le modèle parvient à générer des reconstructions crédibles. De plus, l'architecture simple et modulaire de l'autoencodeur facilite son entraînement et son déploiement, ce qui en fait une solution accessible pour des applications réelles.

Cependant, certaines limites ont été observées. Le modèle a des difficultés à gérer des dégradations extrêmes, notamment lorsque de grandes portions de l'image sont complètement absentes. Dans ces cas, les reconstructions manquent parfois de précision ou de détails. De plus, bien que les résultats soient satisfaisants pour les textures simples, des pertes de qualité sont visibles dans les zones comportant des textures complexes ou des motifs répétitifs.

Ces observations soulignent la nécessité d'améliorer le modèle pour mieux gérer des scénarios plus complexes. Une piste d'amélioration pourrait être l'utilisation de méthodes complémentaires, telles que les GANs ou les autoencodeurs variationnels, pour produire des reconstructions plus détaillées.

En résumé, ce projet démontre que les autoencodeurs convolutifs sont une solution efficace pour la restauration d'images dégradées, tout en mettant en lumière des défis à relever pour atteindre des performances optimales dans des cas extrêmes.

3.4 Conclusion

Les résultats obtenus dans ce projet montrent clairement l'efficacité des autoencodeurs convolutifs pour la restauration d'images dégradées. Grâce à une architecture simple et bien conçue, le modèle a pu gérer divers types de dégradations, produisant des images restaurées de qualité satisfaisante. Les performances qualitatives démontrent la capacité du modèle à reconstruire des images proches des originales, même dans des cas de dégradations modérées à sévères.

Cependant, certaines limites observées, notamment pour les dégradations extrêmes ou les textures complexes, ouvrent des perspectives pour des améliorations futures. Ces observations renforcent l'importance d'un entraînement basé sur des données encore plus variées et l'intégration de méthodes complémentaires pour optimiser les résultats.

Dans l'ensemble, cette section illustre non seulement les forces du modèle, mais également les défis restant à relever, fournissant ainsi une base solide pour des développements futurs dans le domaine de la restauration d'images.

CONCLUSION ET PERSPECTIVES

Ce projet a démontré le potentiel des autoencodeurs convolutifs pour résoudre le problème de la restauration d'images dégradées. En exploitant des techniques modernes d'apprentissage profond, il a été possible de concevoir un modèle capable de gérer une variété de dégradations, y compris le flou, le bruit, le vieillissement, les dommages physiques et les masques. Les résultats qualitatifs obtenus montrent que le modèle peut reconstruire des images avec une fidélité visuelle satisfaisante, même dans des scénarios de dégradations multiples.

L'approche adoptée repose sur une stratégie méthodologique rigoureuse, incluant une préparation minutieuse des données, une architecture de modèle optimisée, et des critères d'évaluation adaptés. Ce projet confirme que les autoencodeurs convolutifs sont une solution prometteuse pour les tâches de restauration d'images, grâce à leur simplicité, leur robustesse et leur efficacité.

Malgré ces succès, certaines limites subsistent, notamment dans la gestion des dégradations extrêmes ou des textures complexes. Ces observations ouvrent la voie à de nombreuses pistes d'amélioration.

BIBLIOGRAPHIE

- [1] : Gonzalez, R. C., & Woods, R. E. (2018). Digital Image Processing. Pearson Education.
- [2] : Zhang, W., et al. (2020). "Limitations of Interpolation Methods for Complex Image Degradations." Journal of Image Science.
- [3] : Chan, T. F., & Shen, J. (2005). "Mathematical Models for Local Non-texture Inpainting." SIAM Journal on Applied Mathematics.
- [4] : Criminisi, A., Perez, P., & Toyama, K. (2004). "Region Filling and Object Removal by Exemplar-Based Image Inpainting." IEEE Transactions on Image Processing.
- [5] : Levin, A., Lischinski, D., & Weiss, Y. (2011). "Natural Image Denoising: Optimal Spatially Adaptive Estimates and Patch-Based Models." IEEE Transactions on Pattern Analysis and Machine Intelligence.
- [6] : Zhang, K., Zuo, W., & Zhang, L. (2017). "Beyond a Gaussian Denoiser: Residual Learning of Deep CNN for Image Denoising." IEEE Transactions on Image Processing.
- [7] : Pathak, D., et al. (2016). "Context Encoders: Feature Learning by Inpainting." Proceedings of CVPR.
- [8] : Isola, P., et al. (2017). "Image-to-Image Translation with Conditional Adversarial Networks." Proceedings of CVPR.
- [9] : Ledig, C., et al. (2017). "Photo-Realistic Single Image Super-Resolution Using a Generative Adversarial Network." Proceedings of CVPR.
- [10] : Kingma, D. P., & Welling, M. (2014). "Auto-Encoding Variational Bayes." arXiv preprint.

TABLE DES MATIÈRES

INTRODUCTION	1
Chapitre 1. ÉTAT DE L'ART	2
1.1 Introduction à la Restauration d'Images	2
1.2 Méthodes existantes	2
1.2.1 Méthodes traditionnelles	2
1.2.1.1 Filtrage spatial et Fréquentiel	2
1.2.1.2 Techniques d'Interpolation	3
1.2.1.3 Les modèles statistiques.	3
1.3 Méthodes Modernes Basées sur le Deep Learning	4
1.3.1 Les réseaux neuronaux convolutifs (CNNs)	4
1.3.2 Autoencodeurs	5
1.3.3 Les réseaux antagonistes génératifs (GANs)	5
1.3.4 Autoencodeurs Variationnels (VAE)	6
1.4 Tableau Comparatif des Méthodes	7
1.5 Synthèse	8
Chapitre 2. MÉTHOLOGIE	9
2.1 Introduction	9
2.2 Description des Données	9
2.3 Architecture du modèle	11
2.4 Stratégie d'entraînement	12
2.5 Outils et environnement technique	14
2.6 Outils et environnement technique	15
Chapitre 3. RÉSULTATS ET DISCUTION	16
3.1 Présentation des résultats	16
3.2 Analyse Qualitative	16

3.3 Discussion	17
3.4 Conclusion	18
CONCLUSION ET PERSPECTIVES	19